paper_analyzer: risultati dei modelli e metriche di valutazione

Riccardo Aldrovandi · 27 ottobre 2026

Sintesi

Sul gold set di 10 paper il modello migliore è Qwen3.8-27B con il ragionamento attivo (*thinking*): L2 0.987 e recall della rubrica 0.952, contro 0.843 e 0.519 del baseline Qwen2.5-14B. Gemma 4 31B con thinking ha la stessa precisione (L2 0.973) ma una recall più bassa di 5.5 punti, differenza statisticamente significativa. Senza thinking Gemma 4 è più preciso di Qwen3.8 (L2 0.84 contro 0.70) a parità di recall. Nella prima fase, con modelli più piccoli, la famiglia Qwen era già la migliore: nel confronto controllato v9 Qwen2.5-14B ottiene L2 0.880 contro 0.667 di Llama-3.1-8B.

Configurazione	L2 [IC 95 %]	Recall [IC 95 %]
Qwen3.8-27B think	0.987 [0.967, 1.000]	0.952 [0.924, 0.977]
Gemma 4 31B think	0.973 [0.944, 0.997]	0.897 [0.859, 0.935]
Gemma 4 31B ctx32k	0.842 [0.754, 0.929]	0.879 [0.835, 0.919]
Qwen2.5-14B (baseline)	0.843 [0.715, 0.956]	0.519 [0.441, 0.591]
Qwen3.8-27B ctx32k	0.705 [0.584, 0.836]	0.876 [0.822, 0.922]

1. Prima fase: modelli piccoli su Leonardo

Tutti i run usano Leonardo (CINECA), vLLM 0.7.3 e due A100 64 GB per job, una per il modello testuale e una per il server di visione. I paper sono tre (Flux tube, Net-proton, GQA) con le stesse 10 figure ritagliate in anticipo; la valutazione è fatta con `main.py evaluate` (L1 e L2, sezione 3).

1.1 Modelli di visione

Probe sul job 59714189: tre figure, temperatura 0, stesso prompt della pipeline. I valori di riferimento sono stati letti a mano dalle figure, quindi i confronti sono indicativi.

Modello	Domande di percezione	Digitalizzazione	Errore medio, curva superiore di Flux tube
Qwen2.5-VL-7B	migliore: legenda esatta, punto 0.1 (vero circa 0.12), barre 55.5 / 55.4 / 55.2	la più fedele sulla figura complessa	circa 0.37
Pixtral-12B	simile a Qwen	buona su Flux tube; inventa su Net-proton (asse logaritmico letto come lineare)	circa 0.45
Idefics3-8B-Llama3	molto scarsa	serie costanti o lineari inventate	circa 0.55
LLaVA-NeXT-Llama3-8B	coglie la struttura ma non i valori	inventa; un'uscita in loop da 8.8k caratteri	trova una curva su due

I modelli di visione basati su Llama sbagliano anche con il chat template corretto, quindi gli errori non dipendono dalla configurazione. Nessun modello rispetta la richiesta di 15–30 punti per curva: tutti restituiscono 4–9 punti in corrispondenza dei tick, e PySR lavora quindi su circa 5 punti. Llama 3.2 Vision e Llama 4 sono stati esclusi perché la licenza non ne consente l'uso nell'Unione Europea.

1.2 Tre famiglie con il proprio modello di visione (run v3–v7)

Ogni cella riporta record validi, figure lette su 10 e L2 medio.

Run	Qwen (14B + VL-7B)	Llama (3.1-8B + LLaVA-NeXT)	Mistral (Nemo-12B + Pixtral)
v3	3/3 · 8 · 0.778	3/3 · 2 · 0.806	3/3 · 8 · 0.556
v4, prompt "copia le formule"	3/3 · L2 0.884	2/3 · 1.000 su 2 record	1/3 · 0.667
v5, recupero dei record	3/3 · 0.907	3/3 · 0.556	2/3 · 0.667
v6, guided JSON sul testo	3/3 · 8 · 0.843	3/3 · 2 · 0.889	3/3 · 7 · 0.833
v7, guided JSON anche sulla visione	3/3 · 9 · 0.926	3/3 · 3 · 0.500	3/3 · 0 · 0.790

Il decoding vincolato a JSON (xgrammar) sul modello testuale porta tutte le famiglie a 9 record validi su 9 senza perdita di qualità ed è rimasto attivo. Con Pixtral il vincolo produce testo senza senso, per un'incompatibilità tra il tokenizer tekken e xgrammar in vLLM 0.7.3, quindi per Mistral è disattivato sulla visione. L'L2 alto di Llama in v6 è gonfiato: LLaVA legge 2–3 figure su 10 e il modello testuale ha poco da riportare.

1.3 Confronto controllato v9

Nei run precedenti cambiavano insieme modello testuale e modello di visione. In v9 (job 60315397 e 60315404) entrambe le famiglie usano Qwen2.5-VL-7B e ricevono un input identico byte per byte; cambia solo il modello testuale.

	Qwen2.5-14B	Llama-3.1-8B
Record validi / L1 superato	3/3 · 3/3	3/3 · 3/3
L2 medio	0.880	0.667
Record con L2 ≥ 0.8	2	0
Formule PySR riportate correttamente	6/12	0/12
Grounding di numeri, riferimenti e dataset	1.0	1.0
Recall della rubrica	0.528	0.583

La differenza di L2 dipende interamente dalle formule: Llama inserisce oggetti JSON dentro le stringhe, non presenta le formule come approssimazioni e ne inventa su Net-proton. Sulla completezza Llama è leggermente avanti.

1.4 Velvet-14B

Velvet-14B (Almawave) è solo testuale; non esiste un modello Velvet di visione e il 25B non è rilasciato. È stato provato con Qwen2.5-VL-7B in quattro job diagnostici e non è utilizzabile come teacher per questo compito. Con le penalità di ripetizione si ferma dopo 2–16 token,

senza penalità va in loop, con penalità corrette si ferma ma copia le descrizioni dello schema o produce JSON non valido. Un prompt breve funziona sempre: il problema è seguire istruzioni su un contesto di circa 9k token.

2. Seconda fase: Qwen3.8-27B e Gemma 4 31B

2.1 Configurazione

Il gold set contiene 10 paper (nove di fisica e uno di machine learning) con figure ritagliate in anticipo; ogni configurazione è eseguita con 3 seed. I modelli girano su Leonardo in un container con vLLM 0.19.1. Qwen3.8-27B usa due GPU (55.9 GB per GPU) e ha visione nativa; Gemma 4 31B ne usa quattro, con visione nativa e contesto di 131k token. Il baseline è la coppia Qwen2.5-14B e Qwen2.5-VL-7B. Le configurazioni sono `ctx32k` e `ctx128k`, senza thinking e con contesto massimo diverso, e `think`, con thinking e fino a 32k token di uscita.

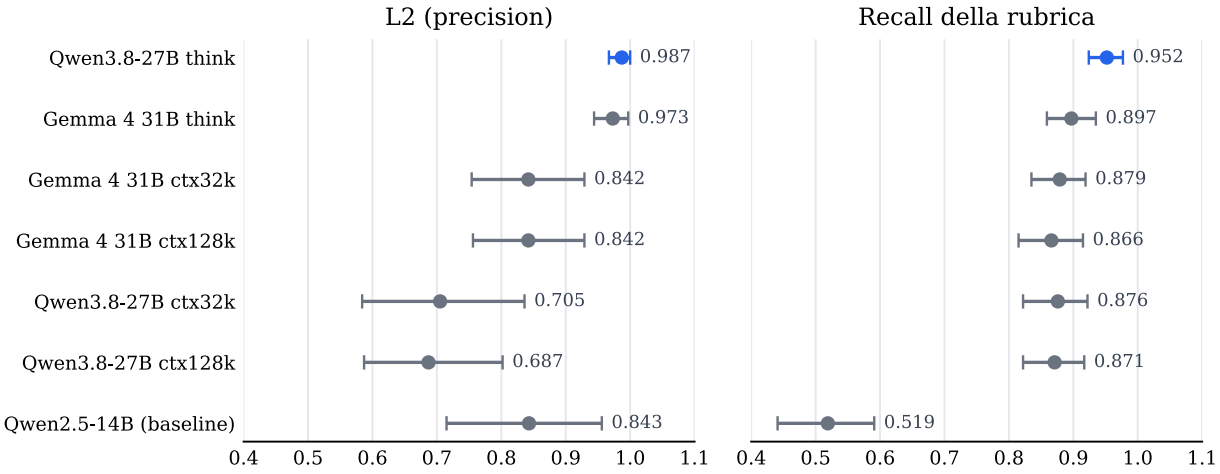


Figura 1. L2 e recall della rubrica per configurazione: media sui 10 paper e intervallo di confidenza bootstrap al 95 %.

2.2 Confronti a coppie

Differenze sui paper in comune, bootstrap con 10 000 ricampionamenti. Una differenza è considerata reale quando il suo intervallo non contiene lo zero.

Confronto	Δ L2 [IC 95 %]	Δ recall [IC 95 %]	Esito
Qwen3.8 think − Qwen2.5-14B	+0.144 [+0.044, +0.255]	+0.432 [+0.347, +0.524]	Qwen3.8 think migliore su entrambe
Qwen3.8 think − Gemma 4 think	+0.014 [0.000, +0.032]	+0.055 [+0.030, +0.084]	stessa precisione, Qwen3.8 più completo
Gemma 4 ctx32k − Qwen3.8 ctx32k	+0.137 [+0.066, +0.208]	+0.003 [−0.030, +0.043]	senza thinking Gemma 4 è più preciso
Gemma 4 think − Qwen2.5-14B	+0.130 [+0.024, +0.244]	+0.378 [+0.286, +0.472]	Gemma 4 think migliore su entrambe
Qwen3.8 ctx128k − ctx32k	−0.018 [−0.073, +0.027]	−0.006 [−0.031, +0.018]	nessuna differenza
Gemma 4 ctx128k − ctx32k	0.000 [−0.006, +0.006]	−0.013 [−0.037, +0.009]	nessuna differenza

2.3 Affidabilità, formule e stabilità

Configurazione	Risposte valide / rifiutate	Formule PySR riportate	Paper con tutti i fatti	Accordo tra seed
Qwen3.8 think	30 / 0	664 / 664	13 / 30	0.58
Gemma 4 think	30 / 0	670 / 696	4 / 30	0.69
Gemma 4 ctx32k	28 / 2	164 / 627	3 / 28	0.76
Gemma 4 ctx128k	26 / 4	157 / 586	2 / 26	0.78
Qwen3.8 ctx128k	27 / 3	50 / 570	2 / 27	0.75
Qwen3.8 ctx32k	21 / 9	52 / 368	3 / 21	0.73
Qwen2.5-14B	30 / 2	55 / 114	0 / 30	0.54

Senza thinking l'L2 scende solo per la componente visiva: il modello non copia le formule PySR nei risultati visivi, mentre numeri e riferimenti restano a 1.0. Le risposte rifiutate senza thinking sono state troncate al limite di 4096 token; una risposta di Gemma 4 ctx128k è andata in loop. Il thinking allunga le risposte e le rende meno stabili tra seed (0.58 contro 0.73 per Qwen3.8), ma più complete.

2.4 Groundedness

La groundedness misura quanta parte di ciò che il modello scrive è sostenuta dal paper. Le stime vengono da un audit manuale stratificato (sezione 3.6), estrapolato a tutti i claim del provider.

Provider	Pienamente supportati [IC 95 %]	Parziali	Falsi [IC 95 %]	Base
Qwen3.8 think	0.883 [0.729, 0.947]	0.117	0.000 [0.002, 0.111]	audit di claim atomici
Qwen2.5-14B	0.778 [0.625, 0.861]	0.207	0.015 [0.010, 0.126]	audit di claim atomici
Tutti i Qwen, frasi intere	0.904 [0.808, 0.945]	0.094	0.002 [0.002, 0.063]	audit di 100 frasi su 1757

La differenza tra Qwen3.8 think e Qwen2.5-14B nei claim pienamente supportati è +0.105 [−0.068, +0.263], con probabilità 0.89 che Qwen3.8 sia migliore: la direzione è favorevole ma il campione non basta a dimostrarla. Per Gemma 4 è disponibile solo il segnale del giudice automatico (VERIFIED 0.60–0.62 e segnalati 0.05, contro 0.44 e 0.07 di Qwen3.8 think), che non è un tasso di errore; l'audit manuale non è ancora stato fatto. Gli errori non riguardano mai i numeri (nessun NUMBER_MISMATCH su 2823 claim atomici) ma generalizzazioni nei campi *experiments* e *future_work* e alcune inversioni causali.

3. Metriche adottate

Ogni metrica risponde a una domanda diversa. Tutte girano offline sui file JSONL prodotti da `export-dataset`, tranne il giudice di groundedness, che richiede una GPU.

Domanda	Metrica	Codice
La risposta è ben formata e non degenere?	L1, filtro strutturale	`src/evaluation/metrics.py`
Ciò che afferma si trova nel paper? (precision)	L2, grounding	`src/evaluation/metrics.py`
Riporta ciò che conta? (recall)	rubrica	`src/evaluation/rubric.py`
Le formule riportate equivalgono a quelle estratte?	equivalenza numerica	`src/evaluation/formulas.py`
Le differenze tra modelli sono rumore?	bootstrap sui paper	`src/evaluation/stats.py`
Ogni affermazione è supportata dal testo?	groundedness a strati e audit	`src/evaluation/groundedness.py`

3.1 L1: filtro strutturale

Una risposta è scartata se il JSON non è valido, mancano chiavi, i tipi sono sbagliati, troppi campi sono vuoti, il testo è in loop, copia gli esempi dello schema o contiene campi di solo riempitivo ("..."). Le soglie sono:

$$\text{empty_ratio} = \frac{|\{k \in P : \text{vuoto}(r_k)\}|}{|P|} \leq 0.5$$

$$\text{rep}_4 = 1 - \frac{|\text{4grammi distinti}|}{|\text{4grammi totali}|} \leq 0.20 \qquad \text{comp} = \frac{|\text{zlib}(t)|}{|t|} \geq 0.25$$

$$\text{sim}(x, e) = \frac{2M}{|x| + |e|} < 0.85$$

P è l'insieme dei campi del paper. rep_4 vicino a 1 indica un testo che si ripete, così come un rapporto di compressione basso. sim è la similarità di `difflib` tra un campo e un esempio del prompt (M caratteri in blocchi comuni) e individua le risposte che ricopiano lo schema, come quelle di Velvet. Le soglie sono una prima stima e non sono state ricalibrate su un output degenere reale.

3.2 L2: grounding

L2 è la media dei componenti verificabili e vale 0 se una formula PySR compare nei campi che descrivono il paper.

$$L2 = \frac{1}{|C|} \sum_{c \in C} s_c \qquad C = \{\text{numeri},\ \text{riferimenti},\ \text{dataset},\ \text{separazione visiva}\}$$

$$s_{\text{num}} = 1 - \frac{|\{n \in N_r : n \notin N_p\}|}{|N_r|} \qquad s_{\text{vis}} = \frac{\text{formule coperte}}{\text{formule}} \left(1 - \frac{\text{findings non inquadrati}}{\text{findings}}\right)$$

N_{r} sono i numeri citati nella risposta (escluse le cifre singole), N_{p} quelli del testo del paper. Allo stesso modo, tabelle, figure, equazioni e algoritmi citati devono esistere nel paper, e ogni dataset deve comparire per nome intero, per acronimo o con almeno metà delle parole significative. Le formule PySR devono stare solo nei risultati visivi ed essere presentate come approssimazioni; se non ci sono formule la componente visiva non entra nella media, per non premiare i modelli che non estraggono nulla. L2 controlla la presenza delle informazioni, non il loro significato, e non dice nulla su ciò che manca.

3.3 Rubrica: completezza

Per ognuno dei 10 paper del gold set la rubrica elenca 8–12 fatti pesati, 150 in tutto, che una buona risposta deve contenere, secondo lo schema dei checkpoint di PRL-Bench (arXiv 2604.15411).

$$\text{Recall} = \frac{\sum_i w_i f_i}{\sum_i w_i} \qquad \text{Strict} = \mathbb{1}[\forall i : f_i = 1] \qquad \frac{|a - v|}{|v|} \le 0.01 \;\; \text{oppure} \;\; \text{round}(a, d_v) = v$$

f_i vale 1 se il fatto è presente: i nomi sono cercati come parole intere, i numeri con la regola a destra (presa da PHYSICS-Verified, con d_v i decimali del valore di riferimento), i testi con gruppi di parole chiave. Le rubriche sono state redatte con l'ausilio di un LLM a partire dal testo dei paper e non sono ancora state revisionate a mano; le parole chiave non riconoscono le negazioni.

3.4 Equivalenza di formule

Una formula riportata dal modello e quella estratta da PySR sono equivalenti se coincidono entro l'1 % su almeno il 90 % di una griglia di 50 punti (40 distribuiti logaritmicamente in [0.05, 300] e 10 negativi):

$$\frac{\left|\left\{x_j \in G : |f(x_j) - g(x_j)| \le \tau \max(|g(x_j)|, 10^{-9})\right\}\right|}{|G_{\text{valido}}|} \ge 0.9 \qquad |G_{\text{valido}}| \ge 10$$

È un test numerico e non una dimostrazione simbolica, e vale solo per formule in una variabile.

3.5 Intervalli di confidenza

L'unità di ricampionamento è il paper; i seed dello stesso paper vengono prima mediati. L'intervallo è il bootstrap percentile al 95 % con B = 10 000 ricampionamenti; nel confronto tra due provider si ricampionano le differenze per paper d_i.

$$\text{IC}_{95\%} = \left[\bar{x}^*_{(0.025B)},\ \bar{x}^*_{(0.975B)}\right] \qquad d_i = \bar{x}_{A,\,i} - \bar{x}_{B,\,i}$$

Con meno di 10 paper in comune l'esito è considerato solo indicativo.

3.6 Groundedness a strati

La valutazione procede in cinque passi.

1. Ogni campo testuale della risposta è scomposto in claim atomici da Qwen3.8; due controlli deterministici scartano gli atomi che aggiungono numeri o parole assenti dalla frase di partenza.
2. Bespoke-MiniCheck-7B stima la probabilità p che il paper supporti il claim. Sul gold di 114 claim ha accuratezza 0.939, sul dev set di SciFact 0.877.
3. Ogni numero di almeno due cifre citato nel claim deve comparire nel paper.
4. Il claim è classificato UNSUPPORTED se $p < 0.5$, DOUBTFUL se $0.5 \le p < 0.85$, VERIFIED se $p \ge 0.85$ e i numeri sono presenti.
5. Un campione di claim per fascia viene verificato a mano (vero, parziale, falso) e il risultato è estrapolato a tutti i claim:

$$\hat{q}_o = \frac{1}{N}\sum_h N_h \frac{k_h}{n_h} \qquad p_h \sim \mathrm{Beta}\big(k_h + \tfrac{1}{2},\ n_h - k_h + \tfrac{1}{2}\big)$$

N_h è il numero di claim nella fascia h e k_h il numero di esiti di tipo o sugli n_h verificati; l'intervallo è credibile al 95 % con priore di Jeffreys. Sui claim reali il giudice da solo non basta: sono veri il 93 % dei VERIFIED ma anche il 57 % degli UNSUPPORTED, quindi le fasce servono a decidere dove guardare e il tasso di errore viene dall'audit.

Il giudice è stato controllato anche su claim reali modificati in modo noto. Confrontati con un paper non correlato, li considera supportati al più nell'1.4 % dei casi; rileva il 93 % dei numeri cambiati e delle negazioni e il 71 % delle inversioni di una parola. Su 40 atomi, un secondo revisore concorda con le etichette dell'audit nell'84 % dei casi nella distinzione vero / non vero (κ = 0.67).

La stabilità tra seed è misurata con il coefficiente di Dice tra i claim di due run:

$$\mathrm{dice}(A, B) = \frac{2|A \cap B|}{|A| + |B|} \qquad \mathrm{agreement}_{i \to j} = \frac{\#\big\{a \in i : \max_{b \in j} \mathrm{dice}(a, b) \geq 0.5\big\}}{|i|}$$

4. Metriche non ancora implementate

Le due mancanze principali sono una valutazione del contenuto campo per campo e una misura dell'accuratezza con cui vengono digitalizzate le figure.

Metrica	Cosa misura	Definizione	Costo	Motivazione
Giudice LLM (G-Eval)	qualità di ogni campo, voto da 1 a 5 rispetto al paper	modello di un'altra famiglia; calibrazione su 20–30 voti umani con ρ di Spearman e κ pesato	medio, un job su Leonardo	unica misura del significato
Errore di digitalizzazione	distanza tra i punti estratti e quelli veri	MAE normalizzato sul range, (1/n) Σ $\lvert\hat{y}_i - y_i\rvert$ / ($y_{max} - y_{min}$), su grafici sintetici con funzione nota	basso	oggi i valori di riferimento sono letti a mano
Qualità delle formule PySR	se la formula descrive la curva o la sovradatta	R^2 su punti tenuti da parte, complessità, numero minimo di punti (almeno 8)	basso, dati già presenti	5 punti con $R^2 = 1$ non dimostrano nulla
Tasso di contraddizione	claim contraddetti, distinti da quelli non supportati	NLI a tre classi, |CONTRADICTED| / |claim|	basso	MiniCheck è binario
FActScore	precisione sui fatti atomici	(1/|A|) Σ 1[a supportato] con recupero delle evidenze	medio	confrontabile con la letteratura
ROUGE-L e BERTScore	somiglianza con un riassunto di riferimento	F della sottosequenza comune più lunga; F1 sulla similarità degli embedding	basso, ma servono riassunti scritti a mano	metriche classiche, premiano la forma più del contenuto
F1 sugli insiemi	contributi e dataset trovati rispetto a quelli attesi	P = |pred ∩ gold| / |pred|, R = |pred ∩ gold| / |gold|, F1 = 2PR / (P + R)	basso	completa la rubrica per i campi lista
F1 sulle evidenze (SciFact)	se il giudice trova le frasi giuste	F1 tra frasi di evidenza predette e annotate	alto, serve annotare le evidenze	il recupero oggi non è misurato
Errore di calibrazione (ECE)	se p = 0.8 corrisponde all'80 % di claim veri	Σ (n_b / n) |acc(b) − conf(b)| sulle fasce di p	basso, dati dell'audit	rende le fasce leggibili come probabilità
SelfCheckGPT	allucinazioni rilevate senza riferimento	un fatto che cambia tra campionamenti diversi è sospetto	medio	sfrutta i tre seed già eseguiti

Metrica	Cosa misura	Definizione	Costo	Motivazione
α di Krippendorff	accordo tra più annotatori	$\alpha = 1 - D_o / D_e$	richiede un secondo annotatore esperto	oggi c'è un solo revisore, non esperto del dominio
Costo ed efficienza	token al secondo, secondi per paper, ore GPU	misure dai log di vLLM	nullo	serve a scegliere il teacher per il dataset

In ordine di convenienza: qualità delle formule PySR e costo, quasi gratuiti; errore di digitalizzazione su grafici sintetici; giudice LLM calibrato, che è la misura più diretta della qualità del contenuto.

5. Modelli open di frontiera su Hugging Face

Senza vincoli di calcolo, i candidati più adatti a paper_analyzer, che deve leggere testo e figure, sono Kimi K3, MiMo-V2.6-Pro e Step 5 Preview: tutti multimodali nativi, con contesto di un milione di token e ai primi posti delle classifiche dei modelli open di ottobre 2026.

Nella tabella, *totali / attivi* indica i parametri complessivi e quelli usati per ogni token nei modelli a esperti (MoE); *pesi* è la dimensione del download nel formato rilasciato; *GPU* è una stima del numero di H100 80 GB necessari, pari a circa 1.2 volte i pesi. Un nodo Leonardo Booster ha 4 A100 64 GB, cioè 256 GB, quindi i modelli oltre i 200 GB richiedono più nodi o macchine più grandi. I modelli sono ordinati per interesse per questo lavoro.

Modello	Totali / attivi	Pesi	GPU	Modalità	Contesto	Licenza	Perché conviene
Kimi K3 (Moonshot, giugno 2026)	2.8T / 104B	1.56 TB	circa 24	testo, immagini, video	1M	Kimi K3, MIT modificata: attribuzione oltre 100M utenti o 20M $ al mese	il più forte tra gli open nel ragionamento scientifico (GPQA Diamond); un solo modello per testo e figure
MiMo-V2.6-Pro (Xiaomi, settembre 2026)	1.02T / 42B	573 GB	8 H200 o 16 H100	testo, immagini, video, audio	1M	MIT	primo modello open nell'indice di Artificial Analysis; licenza più libera; costo per token basso
Step 5 Preview (StepFun, settembre 2026)	600B / 27B	650 GB	circa 16	testo, immagini, video	1M	StepFun: attribuzione oltre soglia, licenza separata per hardware e servizi	pensato per documenti lunghi, grafici e report strutturati, cioè questo caso d'uso
DeepSeek-V4.1-Flash (DeepSeek, ottobre 2026)	552B (763B con la visione) / 8–16B	510 GB	8 H200 o 16 H100	testo, immagini	1M	MIT	multimodale con pochissimi parametri attivi: veloce ed economico per generare il dataset
GLM-5.3-Flash (Z.ai, agosto 2026)	320B / 18B	328 GB	circa 8	testo, immagini	almeno 300K	MIT	primo GLM-5 multimodale, migliore di GLM-5.2 a un decimo del costo

Modello	Totali / attivi	Pesi	GPU	Modalità	Contesto	Licenza	Perché conviene
Muse Spark Open (Meta, ottobre 2026)	816B / 42B	circa 1.6 TB in BF16, esiste una versione NVFP4	circa 24	testo, immagini	1M	Muse Model License, accesso su richiesta, nessuna restrizione geografica	a differenza di Llama 4 è utilizzabile nell'Unione Europea
MiniMax-M3 (MiniMax, giugno 2026)	428B / 23B	854 GB	circa 16	testo, immagini, video	1M	MiniMax Community	multimodale fin dal primo stadio di addestramento
Qwen3.8-Max (Alibaba, agosto 2026)	2.4T / 95B	4.9 TB in BF16, circa 2.4 TB in FP8	oltre 32	solo testo, thinking sempre attivo	262K, estendibile a 1M	Qwen3.8-Max: attribuzione oltre soglia, limiti per servizi sopra 50M $	stessa famiglia di Qwen3.8-27B, il migliore nei test; teacher testuale da affiancare a un modello di visione
GLM-5.3 (Z.ai, agosto 2026)	744B / 40B	756 GB	circa 16	solo testo	1M	GLM-5.3, limiti solo per servizi sopra 10 miliardi $	tra i migliori open nel ragionamento; richiede un modello di visione separato
DeepSeek-V4-Pro (DeepSeek, agosto 2026)	1.6T / 49B	893 GB	circa 16	solo testo	512K	MIT	GPQA Diamond 90.1 %; tre livelli di ragionamento; cache KV ridotta al 10 % rispetto al predecessore
Mistral Medium 3.5 (Mistral, marzo 2026)	128B, denso	267 GB	circa 4	testo, immagini	256K	MIT modificata, eccezioni per grandi aziende	europeo e denso, quindi semplice da servire; quasi entra in un nodo Leonardo
Step-3.7-Flash (StepFun, maggio 2026)	198B, MoE	403 GB	circa 8	testo, immagini	n.d.	Apache 2.0	primo su SimpleVQA (79.2)
Qwen3.8-Flash-Next (Alibaba, agosto 2026)	125B / 6B, più 51B di embedding n-gram	360 GB	circa 8	testo, immagini	fino a 1M	Qwen Community 1.0	stessa famiglia di Qwen3.8-27B, più grande ed efficiente
Mistral Small 4 (Mistral, gennaio 2026)	119B / 6.5B	242 GB	circa 4	testo, immagini	256K	Apache 2.0	europeo e molto veloce; entra in un nodo Leonardo in FP8
MiniMax-M3.1-Flash (MiniMax, ottobre 2026)	428B / 23B	252 GB in FP8	circa 4	testo, immagini, video	1M	MiniMax Community	multimodale recente che entra in 4 GPU
gpt-oss-120b (OpenAI, agosto 2025)	117B / circa 5B	circa 65 GB in MXFP4	1	solo testo	128K	Apache 2.0	riferimento economico, entra in una sola GPU
Gemma 4 31B (Google, aprile 2026)	31B, denso	circa 62 GB	1–2	testo, immagini, video	256K	Apache 2.0	già valutato: termine di confronto per i modelli grandi
Qwen3.8-27B (Alibaba, agosto 2026)	28B, denso	56 GB	1–2	testo, immagini, video	262K	Apache 2.0	già valutato: il migliore finora

Sono esclusi Llama 4 Maverick e Scout, perché la licenza di Llama 4 non consente l'uso dei modelli multimodali nell'Unione Europea, e Kimi K2.6 ed ERNIE-4.5-VL-424B, superati da versioni più recenti. Per usare i modelli più grandi servono vLLM 0.17 o successivo (su Leonardo è già disponibile tramite il container 0.19.1), più di 1 TB di spazio su disco (la quota attuale di `$WORK` è 1 TB) e nodi con più di 4 GPU collegate o un servizio distribuito su più nodi.

6. Limiti

- I risultati della prima fase si basano su 3 paper e sono indicativi; quelli della seconda su 10 paper, sufficienti per gli intervalli di confidenza ma con margini ampi.
- Le rubriche, il gold dei claim e l'audit sono stati annotati da una sola fonte (con l'ausilio di un LLM) e revisionati solo in parte da un revisore non esperto del dominio (40 atomi).
- I valori di riferimento delle figure sono letti a mano; non esiste ancora una misura dell'errore di digitalizzazione.
- Il decompositore dei claim è Qwen3.8, che è anche uno dei modelli valutati: un'eventuale correzione implicita dei propri errori non è rilevabile dai controlli deterministici.
- L2 e la groundedness dicono se un'informazione è nel paper, non se il paper ha ragione.
- Per Gemma 4 manca l'audit manuale della groundedness.
- Le caratteristiche dei modelli della sezione 5 vengono dai model card e dall'API di Hugging Face (consultati il 26 ottobre 2026); i benchmark citati sono dichiarati dai produttori o da classifiche di terzi, non misurati in questo lavoro; le stime delle GPU sono approssimative.

Fonti

- Model card su Hugging Face: Kimi K3, MiMo-V2.6-Pro, Step 5 Preview, DeepSeek-V4.1-Flash, GLM-5.3-Flash, Muse Spark Open, MiniMax-M3, Qwen3.8-2.4T-A95B, GLM-5.3, DeepSeek-V4-Pro, Mistral Medium 3.5, Step-3.7-Flash, Qwen3.8-Flash-Next, Mistral Small 4, MiniMax-M3.1-Flash, gpt-oss-120b, Gemma 4 31B, Qwen3.8-27B.
- Classifiche: confronto Artificial Analysis e BenchLM, BenchLM.
- DeepSeek-V4-Pro su Together AI; GLM-5.3 su Unsloth; licenza di Muse Spark Open.
- Dati sperimentali: `logs_cineca/`, `logs/groundedness_gemma4/`, `gold/`, `docs/METRICS.md`.